

Hasil Evaluasi Model

Beberapa model regresi dikembangkan dan dibandingkan untuk mengevaluasi efektivitas pendekatan machine learning dalam memprediksi waktu tempuh antar segmen. Selain model tunggal (XGBoost, CatBoost, dan LSTM), dilakukan pula eksperimen menggunakan beberapa kombinasi ensemble berbasis *weighted average*.

Model	MAE (detik)	RMSE (detik)
Naive (average_time_sec)	312.21	2266.46
XGBoost	105.35	1206.41
CatBoost	110.23	1326.27
LSTM	108.66	1133.03
Ensemble (CatBoost + LSTM)	103.60	1080.28
Ensemble (XGBoost + CatBoost + LSTM)	99.87	1041.37
Ensemble (XGBoost + LSTM)	99.88	1027.93

Metrik evaluasi tambahan:

- **MAPE rata-rata per segmen: 45.07%**
- **MAE per putaran: 1670.71 detik ($\approx$ 27 menit 51 detik)**
- **Perbaikan terhadap baseline naive (average_time_sec): 68%**

Hasil evaluasi menunjukkan bahwa seluruh model machine learning mampu memberikan peningkatan performa yang signifikan dibandingkan baseline yang hanya menggunakan average_time_sec sebagai prediksi. XGBoost memberikan performa terbaik di antara model tunggal dengan MAE sebesar **105.35 detik**, diikuti oleh LSTM (**108.66 detik**) dan CatBoost (**110.23 detik**).

Pendekatan ensemble memberikan peningkatan performa lebih lanjut. Kombinasi **XGBoost dan LSTM** menghasilkan performa terbaik dengan **MAE sebesar 99.88 detik** dan **RMSE sebesar 1027.93 detik**, lebih baik dibandingkan seluruh model tunggal maupun kombinasi tiga model. Hasil ini menunjukkan bahwa kedua model memiliki karakteristik kesalahan (*error pattern*) yang saling melengkapi, sehingga proses penggabungan prediksi mampu mengurangi kesalahan secara keseluruhan.

Nilai **RMSE yang masih jauh lebih tinggi dibandingkan MAE** mengindikasikan masih terdapat sejumlah kecil observasi dengan kesalahan prediksi yang sangat besar. Kondisi ini konsisten dengan hasil EDA yang menemukan keberadaan outlier ekstrem dan anomali

operasional pada sebagian kecil data, sehingga RMSE yang bersifat lebih sensitif terhadap error besar mengalami peningkatan yang signifikan.

Secara keseluruhan, kombinasi feature engineering, penanganan trip incompleteness menggunakan quality flag, hierarchical backoff untuk mengatasi sparsity, serta pendekatan ensemble XGBoost dan LSTM berhasil meningkatkan kualitas prediksi secara signifikan dibandingkan pendekatan baseline sederhana.

Selain itu, diperoleh **MAPE rata-rata per segmen sebesar 45,07%**, yang menunjukkan bahwa tingkat kesalahan relatif antar segmen masih cukup bervariasi. Variasi ini diperkirakan dipengaruhi oleh karakteristik masing-masing segmen, seperti tingkat kemacetan, jumlah observasi historis yang tidak merata (*sparsity*), serta kondisi operasional yang berubah secara dinamis. Oleh karena itu, evaluasi menggunakan MAPE per segmen memberikan informasi tambahan yang tidak dapat ditunjukkan hanya melalui MAE secara keseluruhan.

Evaluasi pada tingkat perjalanan juga menghasilkan **MAE per putaran sebesar 1670,71 detik** (sekitar **27 menit 51 detik**). Nilai ini menunjukkan bahwa walaupun kesalahan prediksi pada level segmen relatif kecil, akumulasi error di sepanjang satu perjalanan penuh masih cukup besar. Temuan ini menunjukkan adanya peluang pengembangan lebih lanjut, misalnya dengan memperkaya fitur sekuensial, memanfaatkan informasi posisi GPS secara lebih detail, atau menerapkan model sequence-to-sequence agar propagasi kesalahan antar segmen dapat dikurangi.

Secara keseluruhan, kombinasi **feature engineering**, penanganan **trip incompleteness** menggunakan quality flag, pendekatan **hierarchical backoff** untuk mengatasi sparsity, serta **ensemble XGBoost dan LSTM** berhasil meningkatkan kualitas prediksi secara signifikan dibandingkan pendekatan baseline sederhana. Model terbaik mampu menurunkan **MAE sebesar 68,0%** dibandingkan baseline historis, sehingga pendekatan yang diusulkan dinilai efektif sebagai dasar pengembangan sistem prediksi travel time pada data operasional Transjakarta.